

Теория информационного поиска

Лекция 9. Обучение ранжированию

Дмитрий Грановский


СПбГУ

04.05.2026

Ранжирование до этого

- есть основная модель (булева, векторная, ...)
- как-то подбираем коэффициенты для этой формулы, например:
 - веса зон
 - коэффициенты в BM25
- пробуем добавлять расстояния, расширения и прочие *эвристики*

Общая схема машинного обучения



Ранжирование как задача ML

- есть оценки релевантности на парах $\langle q, d_i \rangle$
 - возможно, на тройках $\langle q, d_i, ctx_q \rangle$
 - будем разбивать на обучающую и тестовую выборку
- это классификация или регрессия?
 - ни то ни другое (хотя есть способы свести к ним)
- обычно задача — для произвольной пары документов научиться определять, какой должен быть выше по данному запросу
- функция потерь — например, количество/доля неправильно отранжированных пар

Источники сигнала

- оценки ассессоров
- эксплицитные оценки пользователей
- статистика кликов
 - но бывает так, что поисковая задача решается без клика
- статистика просмотров
- классическая обратная связь по релевантности
 - и по псевдорелевантности

Алгоритм Роккио

- Хотим:

$$q_{opt}^{\vec{}} = \underset{\vec{q}}{argmax} [sim(\vec{q}, C_r) - sim(\vec{q}, C_{nr})]$$

$$q_m^{\vec{}} = \alpha q_0^{\vec{}} + \beta \frac{1}{|D_r|} \sum_{\vec{d}_j \in D_r} \vec{d}_j - \gamma \frac{1}{|D_{nr}|} \sum_{\vec{d}_j \in D_{nr}} \vec{d}_j$$

, где:

- q_o — оригинальный запрос,
- D_r, D_{nr} — множества известных релевантных и нерелевантных документов
- α, β, γ — веса, подбираются

Факторы ранжирования


- 1
 - статические — не зависят от запроса
 - динамические — зависят
 - запросные — не зависят от документа

- 2
 - текстовые
 - TF-IDF, BM25, зоны, ...
 - ссылочные
 - поведенческие
 - свои классификаторы
 - ...


PageRank

- вся коллекция — граф
- качество/важность страницы = вероятности попадания на эту страницу при **случайном блуждании** по ссылкам
- качество/важность страницы определяется количеством ссылок на нее с других страниц
 - ссылки с более важной страницы вносят больший вклад
- исходящие ссылки передают важность поровну
 - то есть если страница P_i имеет важность R_i , то каждая из k ссылок с этой страницы несет вес $\frac{R_i}{k}$
- с вероятностью d вместо перехода по ссылке — переход на случайную страницу


PageRank: пример




PageRank: пример, шаг 1.5




PageRank: пример, шаг 2



PageRank: пример, шаг 2.5



PageRank: пример, шаг 3



Каскадное ранжирование

- проблема: хорошая модель может медленно применяться
- давайте сделаем несколько стадий
 - сначала фильтруем более простой моделью (например, булевой)
 - когда остается не очень много документов, можно применять основную «тяжелую» модель
 - так можно делать много стадий
- хорошо вписывается в распределенную архитектуру

История

- булев поиск
- TF-IDF, BM25
- PageRank
- ...
- градиентный бустинг
- DSSM
- LLM (BERT и др.)